深度学习与自然语言处理第四次作业

姓名：郑梓岳　　学号：19231191

一、 问题描述

基于 Seq2seq 模型来实现文本生成的模型，输入可以为一段已知的金庸小说段落，来生成新的段落并做分析。

二、 Seq2Seq

Seq2Seq 是 Sequence to Sequence 的缩写，是一个 Encoder－Decoder 结构的网络，作用是将一个序列（sequence）映射成另一个序列（sequence）。在 Seq2Seq 框架中包含了两个模块，一个是 encoder 模块，另一个是 decoder 模块。这种同时包含 encoder 和 decoder 的结构与 Auto-Encoder 网络相似，不同的是 Auto-Encoder 模型是将输入通过 encoder 的网络生成中间的结果，并通过 decoder 对中间的结果还原，Auto-Encoder 的模型结构如下图所示：

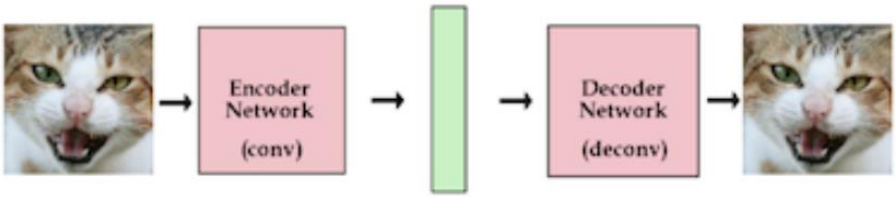

图 1 Auto-encoder 模型结构

Seq2Seq 与 Auto-encoder 相比，相同的是两者都包含了 Encoder 和 Decoder；不同的是，在 Seq2Seq 中，输入与输出并不是相同的，而在 Auto-Encoder 中，输入与输出是相同的。

2.1 Seq2Seq 模型

Seq2Seq 的结构如下图所示：

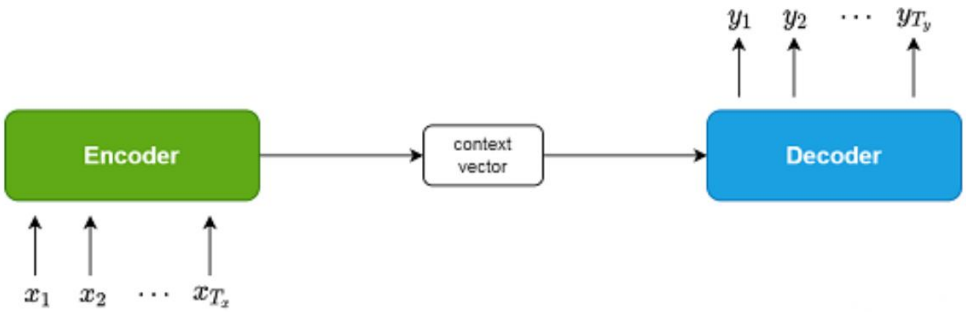

图 2 Seq2Seq 模型结构

在 Seq2Seq 结构中，Encoder 和 Decoder 分别是两个独立的神经网络模型，用于对不同的文本建模，通常对序列化文本建模的方法如 LSTM，RNN 等。Encoder 通过神经网络将原始的输入$\{x_1, x_2, \ldots, x_{T_x}\}$转换为固定长度的中间向量$\{c_1, c_2, \ldots, c_l\}$,Decoder 将此中间向量作为输入，得到最终的输出$\{y_1, y_2, \ldots, y_{T_y}\}$

2.2 Encoder 和 Decoder

本次作业采用 RNN 作为 Encoder 和 Decoder，一个典型的 RNN 结构如下图所示：

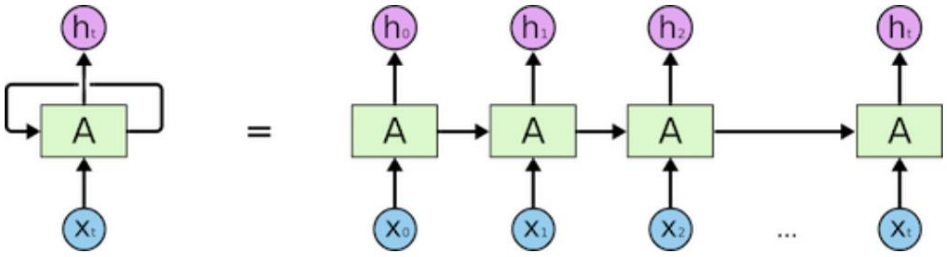

图 3 RNN 结构图

在 RNN 中，在当前时刻t的隐含层状态h_t是由上一时刻$t-1$的隐含层状态h_{t-1}和当前时刻的输入x_t共同决定的，可由下式表示：

$$h_t = f(h_{t-1}, x_t)$$

假设在 Seq2Seq 框架中，输入序列$X = \{x_1, x_2, \ldots, x_{T_x}\}$，其中$x_i \in \mathbb{R}^{K_x}$，输出序列为$Y = \{y_1, y_2, \ldots, y_{T_y}\}$，其中，$y_i \in \mathbb{R}^{K_y}$。

在编码阶段，RNN 通过学习到每个时刻的隐含层状态后，最终得到所有隐含层状态序列：$\{h, h_2, \ldots, h_{T_x}\}$，具体过程如下图所示：

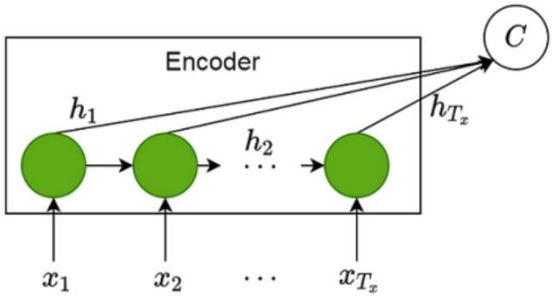

图 4 编码过程展示图

通过对这些隐藏层的状态进行汇总，得到上图中固定长度的语义编码向量C，如下式所示：

$$C = f(h, h_2, \ldots, h_{T_x})$$

其中f表示某种映射函数。通常取最后的隐含层状态h_{T_x}作为语义编码向量C，即

$$C = f(h, h_2, \ldots, h_{T_x}) = h_{T_x}$$

在解码阶段，在当前时刻t，根据在编码阶段得到的语义向量c和已经生成的输出序列

$y_1, y_2, \ldots, y_{t-1}$来预测当前的输出$y_t$，具体过程如下所示：

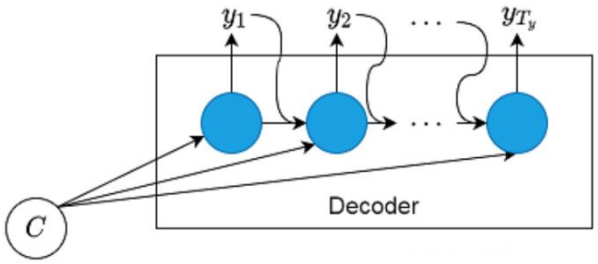

图 5 解码过程展示图

上述过程可以由下式表示：

$$y_t = argmax\ P(y_t) = \prod_{t=1}^{T} p(y_t|y_1, y_2, \ldots, y_{t-1}, c)$$

简化可得：

$$y_t = f(y_t|y_1, y_2, \ldots, y_{t-1}, c)$$

其中f表示某种映射函数。在 RNN 中，上式可简化为：

$$y_t = f(y_{t-1}, s_{t-1}, c)$$

其中y_{t-1}表示$t-1$时刻的输出，s_{t-1}表示 Decoder 中 RNN 在$t-1$时刻的神经元隐藏层的状态，c代表的是 Encoder 网络生成的语义向量。

三、 实验过程

3.1 预料预处理

以金庸的 16 本小说作为语料库。首先需要对语料库进行预处理，保留逗号，去除其他符号，同时去除不含文本信息的部分文字段落。

3.2 模型训练

使用预处理的数据集对 Seq2Seq 模型进行训练。损失函数采用交叉信息熵进行计算。优化器采用 Adam。超参数设计如下：

```
embed_size = 1024
epochs = 25
end_num = 10
```

学习率为 0.0001

3.3 预测

预测过程与训练类似，先输入当前的语句得到 Encoder 的隐层输出，然后将语句起始占位符与该隐层输出输入 Decoder 以预测，持续预测直到输出终止占位符或达到最大的长度。最后通过词表将 One-hot 编码转化为文本。

四、 实验结果及分析

4.1 实验结果

- 训练结果

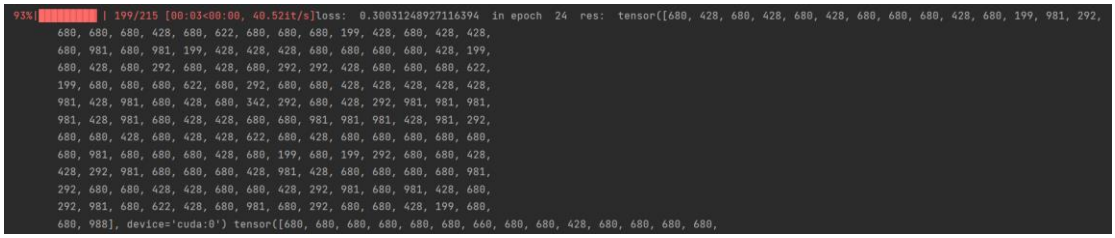

- 预测 1：

输入: 那少妇勒定了马，想伸手去拉，却见丈夫满脸怒容

理想输出: 跟著听得他厉声喝道：「快走！」她一向对丈夫顺从惯了的，只得拍马提缰，向前奔驰，一颗心却已如寒冰一样，不但是心，全身的血都似乎已结成了冰。

预测输出: 却过上便将从将却毒针於说道想心中到

- 预测 2：

输入: 众人万料不到他适才竟是装死，连长枪刺入身子都浑似不觉

理想输出: 斗然间又会忽施反击，一惊之下，六七人勒马退开。虬髯大汉挥动手中雁翎刀，喝道：「李三，你当真是个硬汉！」忽的一刀向他头顶砍落。李三举刀挡架，他双肩都受了重伤，手臂无力，腾腾腾退出三步，哇的一口鲜血喷了出来。十馀人纵马围上，刀枪并举，劈刺下去。

预测输出: 了再下於下他说道又将从心中又便再下著

- 预测 3：

输入: 那少妇远远听得丈夫的一声怒吼，当真是心如刀割

理想输出:「他已死了，我还活著干麼？」从怀中取出一块羊毛织成的手帕，塞在女儿怀里，说道：「秀儿，你好好照料自己！」挥马鞭在白马臀上一抽，双足一撑，身子已离马鞍。

预测输出: 心中了心中後了过上他到过再从

4.2 实验结果分析

从预测的结果来看，对于不同的输入，Seq2Seq 模型都给出了相应的预测输出，虽然各种用字都有金庸小说的风格，但是相对来说缺少语序，存在语句不通顺的问题，可以认为是训练的结果较差，需要调整超参数来获得更好的效果。

五、 总结

本次作业我基于 Seq2seq 模型实现了文本生成的模型，可以通过输入一段已知的小说段落，来生成新的段落。但是本次作业前半段时间我将大量时间放在了本科毕设的准备上，后续的一个星期又不小心新冠阳性，最终用于作业的时间比较紧张，导致最后的训练效果不是很理想，后续我也会加强在这方面的学习，调整模型参数来获得更好的效果。